



TECNOLÓGICO
NACIONAL DE MÉXICO

TECNOLOGICO NACIONAL DE MEXICO, TECNOLOGICO DE CULIACAN



Carrera:

Ingeniería en Sistemas Computacionales

Inteligencia Artificial

11:00 – 12:00

Paradigmas de la Inteligencia Artificial

Nombres:

Osuna Russell Ana Isabel

Rodríguez Valerio Jesús Ricardo

Docente:

Zuriel Dathan Mora Félix

09 de Marzo de 2024

Enfoque Simbólico

El paradigma simbólico, también conocido como IA clásica o GOFAI (Good Old-Fashioned Artificial Intelligence), se basa en la idea de que la inteligencia puede ser representada mediante símbolos y reglas de manipulación de esos símbolos. Este enfoque busca modelar la inteligencia humana a través de la representación explícita del conocimiento y el razonamiento lógico.

Descripción del ejemplo:

Planificación automatizada de rutas de vuelo para aerolíneas. Los sistemas de planificación de rutas de vuelo utilizan la IA simbólica para optimizar las rutas de las aeronaves, considerando factores como el clima, el tráfico aéreo, el consumo de combustible y las regulaciones.

Como el paradigma se aplica:

El sistema se alimenta con representaciones simbólicas del espacio aéreo, aeropuertos, condiciones climáticas, reglas de tráfico aéreo y objetivos de la aerolínea (por ejemplo, minimizar el tiempo de vuelo o el consumo de combustible). A través de algoritmos de búsqueda y planificación simbólica, el sistema genera un plan de vuelo paso a paso que cumple con las restricciones y optimiza los objetivos definidos.

Beneficios:

- **Transparencia y capacidad de explicar:** Las decisiones del sistema son trazables a través de las reglas y la lógica simbólica, lo que facilita la comprensión y la depuración.
- **Capacidad para razonar con reglas y conocimiento explícito:** El paradigma es eficaz para dominios donde el conocimiento puede ser representado de forma clara y las reglas son bien definidas.

Limitaciones:

- **Dificultad para manejar la incertidumbre y el conocimiento incompleto:** El paradigma simbólico tiene dificultades para lidiar con información ambigua o situaciones imprevistas que no están explícitamente codificadas en las reglas.
- **Escalabilidad limitada:** La complejidad de los sistemas simbólicos puede aumentar rápidamente a medida que se incrementa la cantidad de conocimiento y reglas, dificultando su aplicación a problemas muy grandes y complejos.
- **Adquisición del conocimiento:** La construcción de la base de conocimiento y la definición de reglas requiere un esfuerzo manual significativo de expertos en el dominio.

Enfoque Conexionista

El paradigma conexionista, también conocido como redes neuronales o aprendizaje profundo, se inspira en la estructura y el funcionamiento del cerebro humano. Se basa en la creación de redes de unidades interconectadas (neuronas artificiales) que aprenden a través de la modificación de las conexiones (pesos sinápticos) en respuesta a los datos.

Descripción del ejemplo:

Clasificación de imágenes de productos en un sistema de control de calidad industrial. En las líneas de producción, se utilizan sistemas de visión artificial basados en redes neuronales conexionistas para inspeccionar productos y clasificarlos según criterios de calidad (defectuoso/no defectuoso).

Como el paradigma se aplica:

Se entrena una red neuronal con miles de imágenes de productos etiquetadas como "defectuosas" o "no defectuosas". La red aprende a identificar patrones visuales complejos asociados con los defectos a través del ajuste de sus conexiones internas. Una vez entrenada, la red puede clasificar nuevas imágenes de productos con alta precisión.

Beneficios:

- **Aprendizaje automático a partir de datos:** Las redes neuronales pueden aprender patrones complejos directamente de grandes cantidades de datos, sin necesidad de reglas explícitas.
- **Robustez ante datos ruidosos e incompletos:** El paradigma conexionista puede generalizar bien y ser robusto frente a variaciones e imperfecciones en los datos de entrada.
- **Capacidad para resolver problemas complejos y no lineales:** Las redes neuronales son capaces de modelar relaciones complejas y no lineales entre las entradas y salidas, lo que las hace adecuadas para tareas complejas como la visión artificial.

Limitaciones:

- **Falta de transparencia y facilidad de explicar ("caja negra"):** Las decisiones de las redes neuronales pueden ser difíciles de interpretar y explicar, lo que dificulta la depuración y la comprensión de los errores.
- **Necesidad de grandes cantidades de datos de entrenamiento:** El entrenamiento efectivo de redes neuronales requiere conjuntos de datos muy grandes y representativos, lo que puede ser costoso o difícil de obtener.
- **Costo computacional elevado:** El entrenamiento de redes neuronales profundas puede requerir una gran cantidad de recursos computacionales y tiempo.

Enfoque Bioinspirado

El paradigma bioinspirado se inspira en los sistemas biológicos y los procesos naturales para diseñar algoritmos y sistemas inteligentes. Se basa en la idea de que la naturaleza ofrece soluciones eficientes y robustas a problemas complejos, y que estas soluciones pueden ser adaptadas e imitadas para crear sistemas de IA.

Descripción del ejemplo:

Optimización de la distribución de energía en redes inteligentes (Smart Grids) utilizando algoritmos genéticos. En las redes eléctricas inteligentes, los algoritmos genéticos se utilizan para optimizar la distribución de energía, equilibrando la oferta y la demanda, minimizando las pérdidas y maximizando la eficiencia, considerando factores como la variabilidad de las energías renovables y el consumo de los usuarios.

Como el paradigma se aplica:

Se representa cada posible configuración de distribución de energía como un "individuo" en una población. Se evalúa la "aptitud" de cada individuo según criterios de optimización (por ejemplo, eficiencia, costo). A través de procesos inspirados en la evolución biológica (selección, cruce y mutación), se generan nuevas generaciones de individuos, mejorando progresivamente la calidad de las soluciones hasta encontrar una configuración óptima para la distribución de energía.

Beneficios:

- **Capacidad para encontrar soluciones óptimas en espacios de búsqueda complejos:** Los algoritmos bioinspirados, como los genéticos, son eficaces para explorar grandes espacios de soluciones y encontrar soluciones óptimas o casi óptimas a problemas de optimización complejos.
- **Robustez y adaptabilidad:** Los sistemas bioinspirados suelen ser robustos y adaptables a cambios en el entorno, ya que imitan los mecanismos de adaptación de los sistemas naturales.
- **No requieren conocimiento experto del dominio:** En muchos casos, los algoritmos bioinspirados pueden encontrar soluciones sin necesidad de un conocimiento profundo de las características específicas del problema.

Limitaciones:

- **Costo computacional elevado:** Algunos algoritmos bioinspirados, como los algoritmos genéticos, pueden requerir una gran cantidad de recursos computacionales, especialmente para problemas de gran escala.

- **Falta de garantía de encontrar la solución óptima global:** Los algoritmos bioinspirados, en particular los evolutivos, son métodos de búsqueda heurística que no garantizan encontrar la solución óptima global, sino soluciones subóptimas o cercanas al óptimo.
- **Dificultad para interpretar las soluciones:** En algunos casos, las soluciones encontradas por algoritmos bioinspirados pueden ser difíciles de interpretar y comprender, lo que puede limitar su aplicabilidad en dominios donde la explicabilidad es importante.

Enfoque Probabilístico

El paradigma probabilístico utiliza la teoría de la probabilidad y la estadística para modelar la incertidumbre y tomar decisiones racionales en entornos inciertos. Se centra en la representación de la información en términos de probabilidades y en el uso de métodos probabilísticos para el razonamiento y la inferencia.

Descripción del ejemplo:

Detección de fraude en transacciones financieras. Los sistemas de detección de fraude utilizan modelos probabilísticos para evaluar el riesgo de cada transacción, identificando patrones sospechosos y anomalías que podrían indicar actividades fraudulentas.

Como el paradigma se aplica:

Se construye un modelo probabilístico (por ejemplo, una red bayesiana) que representa las relaciones probabilísticas entre diferentes variables relevantes para el fraude (por ejemplo, monto de la transacción, ubicación, hora, historial del usuario). El sistema calcula la probabilidad de fraude para cada transacción basándose en la evidencia observada y las probabilidades aprendidas del modelo. Las transacciones con alta probabilidad de fraude se marcan para una revisión manual.

Beneficios:

- **Manejo de la incertidumbre y el ruido:** El paradigma probabilístico es inherentemente capaz de manejar la incertidumbre y la información incompleta, lo que es crucial en dominios como la detección de fraude donde los datos pueden ser ruidosos y ambiguos.
- **Razonamiento bajo incertidumbre:** Permite tomar decisiones racionales incluso cuando la información es incompleta o incierta, proporcionando una medida de la confianza en las predicciones.
- **Combinación de diferentes fuentes de información:** Los modelos probabilísticos pueden integrar fácilmente diferentes tipos de información y evidencia para mejorar la precisión de las predicciones.

Limitaciones:

- **Complejidad de la construcción del modelo:** La construcción de modelos probabilísticos precisos y eficientes puede ser compleja y requerir un conocimiento experto en estadística y probabilidad.
- **Necesidad de datos para estimar probabilidades:** La estimación precisa de las probabilidades en el modelo requiere datos históricos relevantes y de calidad.

- **Supuestos de independencia:** Muchos modelos probabilísticos asumen independencia entre variables para simplificar el cálculo, lo que puede no ser realista en algunos dominios y afectar la precisión.

Enfoque Computacional

El paradigma computacional se centra en el desarrollo de algoritmos y modelos computacionales para resolver problemas de inteligencia artificial. Este paradigma abarca una amplia gama de técnicas y enfoques, desde algoritmos de búsqueda y optimización hasta modelos basados en lógica y razonamiento. El énfasis está en la eficiencia y la efectividad computacional para resolver problemas específicos.

Descripción del ejemplo:

Sistemas de recomendación de películas y series en plataformas de streaming. Estos sistemas utilizan algoritmos computacionales para analizar el historial de visualización, las preferencias y las valoraciones de los usuarios, así como la información sobre el contenido (género, actores, directores, etc.) para recomendar películas y series que sean de su interés. Un ejemplo de algoritmo podría ser el filtrado colaborativo basado en vecinos más cercanos (k-NN).

Como el paradigma se aplica:

El sistema computacionalmente analiza grandes conjuntos de datos de usuarios y contenido. En el caso del filtrado colaborativo k-NN, para un usuario dado, el algoritmo identifica a los usuarios más "similares" basándose en sus historiales de visualización. Luego, recomienda contenido que ha sido bien valorado por estos usuarios similares pero que el usuario objetivo aún no ha visto. El algoritmo k-NN realiza cálculos de distancia y búsqueda de vecinos para generar recomendaciones personalizadas.

Beneficios:

- **Eficacia para tareas específicas:** El paradigma computacional permite desarrollar algoritmos y modelos altamente eficientes para resolver problemas específicos de IA, como la recomendación, la clasificación o la predicción.
- **Flexibilidad y adaptabilidad:** Existe una amplia variedad de algoritmos y técnicas computacionales que pueden ser adaptadas y combinadas para abordar diferentes tipos de problemas y dominios.
- **Fácil de implementar:** dada la simplicidad y precisión del algoritmo, es uno de los primeros clasificadores que aprenderá un nuevo científico de datos.

Limitaciones:

- **Puede requerir un diseño y ajuste manual del algoritmo:** En muchos casos, el diseño y la optimización de algoritmos computacionales requiere un conocimiento experto y un proceso de prueba y error para lograr un buen rendimiento.

- **Dificultad para generalizar a problemas nuevos o no vistos:** Los algoritmos computacionales pueden ser muy específicos para el problema para el que fueron diseñados, y pueden no generalizar bien a problemas nuevos o ligeramente diferentes.
- **Falta de interpretabilidad en algunos casos:** Algunos modelos computacionales complejos pueden ser difíciles de interpretar y explicar, aunque en el ejemplo del k-NN, la lógica de recomendación es relativamente transparente.

Referencias

- Poole, D., & Mackworth, A. (2017). Artificial Intelligence: foundations of computational agents. Cambridge University Press.
- Russell, S. J., & Norvig, P. (2021). Artificial intelligence: a modern approach. Pearson Education.
- Floreano, D., & Mattiussi, C. (2008). Bio-inspired artificial intelligence: theories, methods, and systems. MIT press.